

VERİ MADENCİLİĞİ DERSİ DÖNEM PROJESİ KAPSAMLI SONUÇ RAPORU

Proje Adı: Şehir İçi Trafik Sensör Verileri ile Yoğunluk Seviyesi Sınıflandırması ve Araç Sayısı Tahmin Uygulaması

Geliştirici Takım:

Muhammet Mustafa Mencik –Veri Ön İşleme Sorumlusu

Kağan Aydın – Veri Analisti / Proje Planlama

Baran Demir – Makine Öğrenmesi Geliştirici

Mehmet Açıkgöz – Arayüz ve Yazılım Geliştirici

1. ÖZET

Bu proje kapsamında, metropollerde yaşanan trafik sorunlarına veri odaklı bir çözüm sunmak amacıyla "Şehir İçi Trafik Sensör Verileri ile Yoğunluk Seviyesi Sınıflandırması ve Araç Sayısı Tahmin Uygulaması" geliştirilmiştir. Proje, Scrum proje yönetim metoduyla 4 sprint halinde yürütülmüştür. İBB Açık Veri Portalı'ndan elde edilen yaklaşık 15.000 satırlık temiz veri seti üzerinde hem sınıflandırma (Random Forest) hem de regresyon (XGBoost/Random Forest) modelleri eğitilmiştir. Eğitilen modeller, Streamlit kütüphanesi ile kullanıcı dostu bir arayüze entegre edilerek canlı ve anlık tahmin yapabilen bir karar destek sistemine dönüştürülmüştür.

2. PROBLEM TANIMI VE PROJE AMACI

Günümüzde şehir içi trafik yoğunluğunun anlık olarak doğru tahmin edilebilmesi, rotalama algoritmalarından şehir planlamasına kadar birçok alanda kritik bir öneme sahiptir. Bu çalışmanın temel amacı; zaman (saat, haftanın günü) ve konum bazlı sensör verilerini kullanarak:

Trafik yoğunluğunu kategorik olarak ("Az", "Orta", "Çok") sınıflandırmak, belirli bir saat diliminde geçecek tam araç sayısını sayısal (regresyon) olarak tahmin etmektir.

3. VERİ SETİ SEÇİMİ VE VERİ ÖN İŞLEME (Data Preprocessing)

Veri Madenciliği dersi proje yönergelerinde belirtilen "tabular veri setleri için minimum 1000, tercih edilen 5000 ve üzeri satır" kriteri projemizin temel çerçevesini oluşturmuştur. Çok küçük ölçekli veri setlerinin modelin genelleme yeteneğini düşüreceği ve performans ölçümlerini yanıltacağı ve veri setinin genellemelerinin günlük hayata daha ilgili olması amacıyla İBB Açık Veri Portalı kullanılmıştır.

Veri Seti Büyüklüğü: Eksik (null) değerlerin pandas kütüphanesi dropna() fonksiyonu ile temizlenmesinin ardından veri seti 15.000 satıra indirilmiştir.

Öznitelik Çıkarımı (Feature Engineering): Ham verideki araç sayıları temel alınarak hedef değişkenimiz (Yogunluk) oluşturulmuştur.

0-100 araç "Az",

100-300 araç "Orta",

300+ araç ise "Çok" olarak etiketlenmiştir.

Kullanılan Öznitelikler: Modele girdi olarak

“['DATE_TIME', 'LATITUDE', 'LONGITUDE', 'GEOHASH', 'MINIMUM_SPEED', 'MAXIMUM_SPEED', 'AVERAGE_SPEED', 'NUMBER_OF_VEHICLES', 'Yogunluk']” sütunları verilmiştir.

4. PROJE YÖNETİMİ VE SCRUM METODOLOJİSİ

Proje yönergesinde kullanılması istenilen Scrum modeli ekibimiz tarafından uygulanmış ve proje toplam 4 Sprint'e bölünmüştür. İki haftalık periyotlarla Scrum Master rolü takım üyeleri arasında (Muhammet Mustafa Mencik, Kağan Aydın, Baran Demir, Mehmet Açıkgöz) dönüşümlü olarak yürütülmüştür.

Sprint 1: Veri setinin belirlenmesi, İBB portalından çekilmesi ve Scrum tahtasının (Trello) kurulumu.


Sprint 2: Verilerin temizlenmesi, boş değerlerin silinmesi, yeni özniteliklerin (Yoğunluk) üretilmesi ve EDA (Keşifçi Veri Analizi) sürecinin tamamlanması.

Sprint 3: Makine Öğrenmesi modellerinin (Sınıflandırma ve Regresyon) kurulması, eğitilmesi ve ".pkl" formatında dışa aktarılması.

Sprint 4: Modellerin Streamlit arayüzüne entegre edilmesi, canlı demo testleri ve final raporlaması.

İletişim ve Kriz Yönetimi:

Ekip üyelerinin sürekli aynı fiziksel ortamda bulunamaması projedeki temel iletişim krizlerinden biri olmuştur. Bu durum, Trello üzerinde dijital bir Scrum tahtası ("Yapılacaklar", "Devam Edenler", "Bitenler") kurularak ve Whatsapp gruplarını iletişim aracı kullanarak aşılmıştır.



Grup 18 Scrum Toplantı Notları

Sprint 1: Planlama ve Veri Keşfi Toplantısı (Scrum Master: Kağan Aydın)

- **Toplantı Yeri:** Whatsapp Grubu
- **Gündem:** Proje konusunun netleştirilmesi ve veri setinin seçimi.
- **Alınan Kararlar:** Oyuncak veriler yerine, yerel ve gerçek bir problem olan İBB Açık Veri Portalı saatlik trafik verilerinin kullanılmasına karar verilmiştir. Veri çekme ve görevlerin Trello'ya girilmesi işini Mustafa üstlenmiştir.

Sprint 2: Veri Ön İşleme ve Keşifçi Analiz Toplantısı (Scrum Master: M. Mustafa Mencik)

- **Toplantı Yeri:** Fakülte Kantini
- **Gündem:** İBB verisinin temizlenmesi ve görselleştirilmesi.
- **Alınan Kararlar:** İBB verisinin milyonlarca satır içermesi nedeniyle sistem kilitlenmelerini önlemek adına 15.000 satırlık temiz bir örneklem alınmıştır (5000+ kuralı aşıldı). Kağan tarafından EDA (Keşifçi Veri Analizi) grafikleri çıkarılmış ve sınıf dengesizlikleri tespit edilmiştir.

Sprint 3: Makine Öğrenmesi Modelleme Toplantısı (Scrum Master: Baran Demir)

- **Toplantı Yeri:** Google Meet
- **Gündem:** Sınıflandırma ve regresyon modellerinin kurulumu.
- **Alınan Kararlar:** Temizlenen veri Baran'a iletilmiş ve Random Forest algoritmaları ile eğitimlere başlanmıştır. Sınıf dengesizliğini aşacak parametreler ayarlanmış ve elde edilen tatmin edici sonuçlar (.pkl dosyaları) arayüz için hazırlanmıştır.


Sprint 4: Entegrasyon, Test ve Teslim Toplantısı (Scrum Master: Mehmet Açıkgöz)

- **Toplantı Yeri:** Ortak Whatsapp Grubu ve Fakülte Kantini
- **Gündem:** Modellerin Streamlit arayüzüne bağlanması ve sunum provası.
- **Alınan Kararlar:** Baran'ın eğittiği modeller, Mehmet tarafından başarıyla Streamlit web arayüzüne entegre edilmiş ve sistemin anlık tahmin yapabildiği test edilmiştir.

Hazırlanan rapor onaylanmış, 10 dakikalık sunumun zamanlaması ve prova işlemleri tamamlanmıştır. Proje teslim hazırdır.

5. KEŞİFÇİ VERİ ANALİZİ (EDA)

Temizlenen veriler üzerinde İstanbul trafiğinin yoğunluğunu ve değişimlerini anlamak adına görselleştirme çalışmaları yapılmıştır. Ekim ayının seçilmesinin temel nedeni; mevsimsel ekstrem koşulların (kar, yoğun fırtına vb.) olmadığı ve okulların açık olduğu "tipik" bir İstanbul trafiğini temsil etmesidir.



Şekil 1: Ekim ayı boyunca sensörlerden gelen anlık ham zaman serisi verisi. Veriler trafiğin anlık yüksek frekanslı dalgalanmalarını (pik noktalarını) kaybetmemek adına tüm zaman damgaları (timestamp) korunarak çizdirilmiştir. X eksenindeki yoğunluk, 15.000 veri noktasının anlık akışını temsil etmektedir.


Proje yönergesinde hocamızın özellikle vurguladığı “modelin veriyi ezberlemesine (overfitting) engel olup öğrenmesini sağlama” kuralı projenin bu aşamasında merkeze alınmıştır. Sınıflar arası (Az, Orta, Çok) veri sayısı dengesizliklerinin modelin tek bir sınıfı ezberlemesine yol açmaması için dağılımlar kontrol edilmiş ve veri seti %80 Eğitim (Train), %20 Test olarak ayrılmıştır.

6.1. Sınıflandırma Modeli (Yoğunluk Tahmini)

Yoğunluk sınıflarını tahmin etmek için Random Forest Classifier kullanılmıştır.

Model Başarısı (Accuracy): %78.50

F1-Score Değerleri: 0.77 (Sınıf bazında: Az 0.88, Orta 0.60, Çok 0.52)



Şekil 2: Sınıflandırma modeline ait Karmaşıklık Matrisi (Confusion Matrix).

6.2. Regresyon Modeli (Araç Sayısı Tahmini)

Kesin araç sayısını tahmin etmek için “ Random Forest Regressor ” kullanılmıştır.

Ortalama Mutlak Hata (MAE): 53.96 araç

Hata Kareleri Ortalaması Karekökü (RMSE): 91.99

7. ARAYÜZ TASARIMI VE CANLI UYGULAMA (Streamlit Entegrasyonu)

Projenin sadece arka planda çalışan kodlardan ibaret kalmaması ve son kullanıcıya hitap eden bir ürüne dönüşmesi amacıyla Streamlit kütüphanesi kullanılarak bir web arayüzü geliştirilmiştir.

Python pickle kütüphanesi ile dışa aktarılan eğitilmiş modeller arayüze entegre edilmiştir. Kullanıcıdan alınan "Saat" ve "Gün" gibi girdiler anlık olarak modele iletilmekte ve sistem ekrana iki farklı çıktı vermektedir:

“Beklenen Yoğunluk Durumu (Sınıflandırma Çıktısı)”

“Beklenen Araç Sayısı (Regresyon Çıktısı)”



Şekil 3: Geliştirilen "İstanbul Trafik Tahmin Sistemi" kullanıcı arayüzü.

8. SONUÇ VE DEĞERLENDİRME

Bu proje, ders kapsamında öğrendiğimiz veri madenciliği tekniklerini sadece kağıt üzerinde bırakmayıp, gerçek ve karmaşık bir probleme (İstanbul trafiğine) uygulamamızı sağladı. Projeye başlarken İBB'den aldığımız milyonlarca satırlık ham veriyi temizlemek, eksiklikleri gidermek ve makine öğrenmesine uygun hale getirmek sürecin zorlu ama en öğretici adımlarından biriydi.

Fiziksel olarak sürekli bir araya gelememe dezavantajımızı Scrum metodolojisine sıkı sıkıya bağlı kalarak ve Trello üzerinden şeffaf bir görev takibi yaparak aşmaya çalıştık. Modelleme aşamasında hocamızın da özellikle uyardığı "veri dengesizliği ve ezberleme" sorunlarıyla yüzleştik; ancak veriyi doğru parçalara bölerek ve uygun algoritmaları seçerek modellerimizin (Random Forest ve XGBoost) veriyi ezberlemeden, gerçekten öğrenerek mantıklı tahminler yapmasını başardık.

Sonuç olarak; veri çekme adımından başlayıp, model eğitmeye ve en sonunda Streamlit ile çalışan bir kullanıcı arayüzü tasarlamaya kadar giden bu süreci, sadece bir ödev olarak değil uçtan uca bir yazılım projesi olarak ele aldık. Geliştirdiğimiz bu karar destek sisteminin, anlık çalışan canlı bir uygulamaya dönüştüğünü görmek, takım olarak bizim için projenin en tatmin edici çıktısı oldu.